



Chapitre 2:

PRÉTRAITEMENT DES DONNÉES

Principes fondamentaux du Machine Learning

Objectifs

L'objectif de ce chapitre est de montrer l'importance du prétraitement des données dans un projet de Machine Learning. Nous allons :

- Expliquer les concepts de base liés aux données et leur nécessité de préparation.
- Présenter deux techniques essentielles de prétraitement :

Objectifs

L'objectif de ce chapitre est de montrer l'importance du prétraitement des données dans un projet de Machine Learning. Nous allons :

- Expliquer les concepts de base liés aux données et leur nécessité de préparation.
- Présenter deux techniques essentielles de prétraitement :
 - ▶ **Nettoyage des données** : Comment identifier et gérer les valeurs manquantes, les valeurs aberrantes et les erreurs.

Objectifs

L'objectif de ce chapitre est de montrer l'importance du prétraitement des données dans un projet de Machine Learning. Nous allons :


- Expliquer les concepts de base liés aux données et leur nécessité de préparation.
- Présenter deux techniques essentielles de prétraitement :
 - ▶ **Nettoyage des données** : Comment identifier et gérer les valeurs manquantes, les valeurs aberrantes et les erreurs.
 - ▶ **Transformation des données** : Comment ajuster les données pour qu'elles soient prêtes à être analysées.

Plan

- ① Introduction
- ② Notions de Bases
- ③ Les techniques de prétraitement des données
 - ① Data cleaning
 - ② Data transformation

1. Introduction


L'apprentissage automatique nécessite de grandes quantités de données , mais les données brutes provenant de diverses sources (audio, vidéo, texte, etc.) ne sont pas directement exploitables. Le prétraitement des données est une étape cruciale qui consiste à nettoyer, transformer et formater ces données afin qu'elles puissent être utilisées efficacement par les algorithmes. Bien que cette phase soit essentielle pour la réussite du projet, elle est souvent la plus longue et la plus complexe.



2. Notions de base

Types de variables

Les variables présentes dans le dataset peuvent être de différents types :



- **Les variables qualitatives** (ou variables catégorielles) qui expriment une caractéristique :
 - ▶ **Ordinales** (avec une hiérarchie ou un ordre) :
 - ★ « un peu, beaucoup », « passionnément, à la folie »
 - ★ « primaire, secondaire, universitaire »
 - ★ « insatisfait, neutre, satisfait »
 - ▶ **Nominales (sans ordre)** :
 - ★ « femme, homme »
 - ★ « bleu, vert, marron »
 - ★ « Tunisie, Algérie, Maroc »
- **Les variables quantitatives** qui ont une valeur numérique :
 - ▶ **Discrètes** : seulement certaines valeurs sont possibles (souvent des entiers).
 - ▶ **Continues** : n'importe quelle valeur est possible dans un intervalle.

Exemple: Pour les exemples suivants, pensez-vous que ce sont des variables **qualitatives, quantitatives discrètes** ou **quantitatives continues** ?

- Le nombre d'appels reçus par un centre d'appels en une heure :

Exemple: Pour les exemples suivants, pensez-vous que ce sont des variables **qualitatives**, **quantitatives discrètes** ou **quantitatives continues** ?

- Le nombre d'appels reçus par un centre d'appels en une heure : **Quantitative discrète**
- Poids :

Exemple: Pour les exemples suivants, pensez-vous que ce sont des variables **qualitatives**, **quantitatives discrètes** ou **quantitatives continues** ?

- Le nombre d'appels reçus par un centre d'appels en une heure : **Quantitative discrète**
- Poids : **Quantitative continue**
- Lancer d'un dé :

Exemple: Pour les exemples suivants, pensez-vous que ce sont des variables **qualitatives**, **quantitatives discrètes** ou **quantitatives continues** ?

- Le nombre d'appels reçus par un centre d'appels en une heure : **Quantitative discrète**
- Poids : **Quantitative continue**
- Lancer d'un dé : **Quantitative discrète**
- Quantité de chocolat consommée en une année :

Exemple: Pour les exemples suivants, pensez-vous que ce sont des variables qualitatives, quantitatives discrètes ou quantitatives continues ?

- Le nombre d'appels reçus par un centre d'appels en une heure : **Quantitative discrète**
- Poids : **Quantitative continue**
- Lancer d'un dé : **Quantitative discrète**
- Quantité de chocolat consommée en une année : **Quantitative continue**
- Être gaucher ou droitier :

Exemple: Pour les exemples suivants, pensez-vous que ce sont des variables **qualitatives**, **quantitatives discrètes** ou **quantitatives continues** ?

- Le nombre d'appels reçus par un centre d'appels en une heure : **Quantitative discrète**
- Poids : **Quantitative continue**
- Lancer d'un dé : **Quantitative discrète**
- Quantité de chocolat consommée en une année : **Quantitative continue**
- Être gaucher ou droitier : **Qualitative nominale**

3. Les techniques de prétraitement des données



Data Cleaning

Gestion des valeurs manquantes
Traitement des valeurs aberrantes
Suppression des doublons



Data Reduction

Réduire la taille de l'ensemble de données tout en préservant les informations importantes



Data Transformation

Normalisation
Standardisation
Encodage des variables



Feature Engineering

Créer des nouvelles variables à partir des données disponibles




Feature selection

Identifier les variables les plus pertinentes

Dans ce chapitre, on se limitera au **Data Cleaning** et au **Data Transformation**


Data Cleaning

Le **nettoyage des données** (ou **data cleaning**) est une étape cruciale dans le processus de prétraitement des données, visant à améliorer la qualité des données avant de les utiliser dans des analyses ou des modèles d'apprentissage automatique.



Data Cleaning

Le **nettoyage des données** (ou **data cleaning**) est une étape cruciale dans le processus de prétraitement des données, visant à améliorer la qualité des données avant de les utiliser dans des analyses ou des modèles d'apprentissage automatique.



Les principales techniques associées au nettoyage des données :

- **Gestion des valeurs manquantes**
- **Suppression des doublons**
- **Traitements des valeurs aberrantes** (également appelées *outliers*)

Gestion des valeurs manquantes:

Les valeurs manquantes font référence aux données qui n'ont pas été collectées ou qui sont absentes dans un ensemble de données. Cela peut se produire pour diverses raisons, comme un participant qui n'a pas répondu à une question, des erreurs de mesure, ou des échantillons non disponibles.

La gestion des valeurs manquantes est essentielle dans l'analyse des données. Deux méthodes couramment utilisées sont **la suppression et l'imputation des valeurs manquantes**.

	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	NaN
1	9	NaN	9.0	0	7.0
2	19	17.0	NaN	9	NaN

Valeurs manquantes

Gestion des valeurs manquantes: Suppression

La suppression des valeurs manquantes consiste à retirer les observations ou les caractéristiques contenant des données incomplètes. Deux approches principales :

Gestion des valeurs manquantes: Suppression

La suppression des valeurs manquantes consiste à retirer les observations ou les caractéristiques contenant des données incomplètes. Deux approches principales :

Suppression par ligne :

- Retire toute ligne où au moins une valeur est manquante.
- Idéal si le nombre de valeurs manquantes est faible.

Gestion des valeurs manquantes: Suppression

La suppression des valeurs manquantes consiste à retirer les observations ou les caractéristiques contenant des données incomplètes. Deux approches principales :

Suppression par ligne :

- Retire toute ligne où au moins une valeur est manquante.
- Idéal si le nombre de valeurs manquantes est faible.

Suppression par colonne :

- Élimine les colonnes entières si une proportion significative de données est manquante (ex. $> 30\%$).
- Utile pour supprimer les caractéristiques peu informatives.


Avantage : Méthode simple et rapide.

Inconvénient : Peut entraîner une perte de données précieuses.

Gestion des valeurs manquantes: Imputation

L'imputation consiste à remplacer les valeurs manquantes par des valeurs estimées ou prédites fondées sur les données disponibles

Data Imputation



What is data imputation?

Méthodes d'imputation	Moyenne	Médiane	Mode	Autres méthodes
Définition	Remplacer les valeurs manquantes par la moyenne des valeurs présentes dans la même colonne. ⚠ Sensible aux valeurs aberrantes !!!	Les valeurs manquantes sont remplacées par la médiane de la colonne, une méthode plus robuste que la moyenne en présence de valeurs aberrantes.	Les valeurs manquantes sont remplacées par la valeur la plus fréquente dans la colonne. ⚠ Sensible aux valeurs aberrantes !!!	Imputation par des algorithmes de machine Learning, exemple: méthode des k plus proches voisins (KNN)
Formule	$\frac{1}{n} \sum_{i=1}^n x_i$ avec x_i : les valeurs non manquantes présentes dans la même colonne, n: nombre des valeurs non manquantes	Si n est impaire alors $x_{(\frac{n+1}{2})}$ Si n est paire alors $(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)})/2$ avec x_i : la valeur non manquante d'ordre i		
Type de variables	Variables numériques continues	- Variables numériques continues - Variables ordinaires (transformées d'abord en valeurs numériques)	- Variables qualitatives (s'applique directement à ces variables sans conversion en valeurs numériques).	

Exemple:

➤ Imputation par mode

Satisfaction	Satisfaction
Bon	Bon
Mauvais	Mauvais
Moyen	Moyen
NaN	Bon
Bon	Bon
NaN	Bon
Bon	Bon
Mauvais	Mauvais



➤ Imputation par median:

Âge	Âge
25	25
30	30
NaN	29
28	28
35	35
NaN	29




➡ Remarque: Pour calculer la médiane, les valeurs non manquantes doivent être triées dans un ordre croissant

Gestion des valeurs aberrantes

Qu'est-ce qu'une valeur aberrante (ou extrême) ?


Une valeur extrême (outlier) est une observation “qui semble dévier notablement des autres éléments de l'échantillon auquel elle appartient” (Grubbs, 1969)



Gestion des valeurs aberrantes

Qu'est-ce qu'une valeur aberrante (ou extrême) ?

Une valeur extrême (outlier) est une observation “qui semble dévier notoirement des autres éléments de l'échantillon auquel elle appartient” (Grubbs, 1969)




Quelles sont les causes des valeurs extrême?

Les valeurs extrêmes peuvent être des erreurs humaines (ex: erreurs de saisie), erreurs d'instrument (ex: erreurs de mesure), erreurs de traitement des données (ex: manipulation des données) et erreurs d'échantillonnage (ex: extraction des données de mauvaises sources.)

Gestion des valeurs aberrantes

Qu'est-ce qu'une valeur aberrante (ou extrême) ?

Une valeur extrême (outlier) est une observation “qui semble dévier notablement des autres éléments de l'échantillon auquel elle appartient” (Grubbs, 1969)



Quelles sont les causes des valeurs extrême?

Les valeurs extrêmes peuvent être des erreurs humaines (ex: erreurs de saisie), erreurs d'instrument (ex: erreurs de mesure), erreurs de traitement des données (ex: manipulation des données) et erreurs d'échantillonnage (ex: extraction des données de mauvaises sources.)

Solution → Supprimer ou imputer selon le cas

Les valeurs extrêmes peuvent être légitimes:

- **Variations naturelles** : Ex. Revenus très élevés (personne très riche).
- **Cas rares mais réels** : Ex. Phénomènes météorologiques extrêmes.

Solution: Conserver, mais utiliser des méthodes comme la transformation logarithmique pour réduire leur impact sur certaines analyses.

Exemple : Revenus avant (1000, 2000, 10 000) → après $\ln(x)$: (6.9, 7.6, 9.2)

Les valeurs extrêmes peuvent être légitimes:

- **Variations naturelles** : Ex. Revenus très élevés (personne très riche).
- **Cas rares mais réels** : Ex. Phénomènes météorologiques extrêmes.

Solution: Conserver, mais utiliser des méthodes comme la transformation logarithmique pour réduire leur impact sur certaines analyses.

Exemple : Revenus avant (1000, 2000, 10 000) → après $\ln(x)$: (6.9, 7.6, 9.2)

Remarque: Une valeur extrême n'est pas automatiquement une erreur. Il est important d'examiner le contexte de vos données pour déterminer si une valeur aberrante est une observation légitime ou le résultat d'une erreur

Exemple

Données brutes (non triées):

5, 7, 8, 12, 15, 16, 18, 22, 24, 30, 100

Étape 1 : Trier les données en ordre croissant

⇒ 5, 7, 8, 12, 15, 16, 18, 22, 24, 30, 100

Étape 2 : Calcul des quartiles

⇒ 1er quartile (Q1) = 8 ; 2ème quartile (Q2) = médiane = 16 ; 3ème quartile (Q3) = 24

Étape 3 : Calcul de l'intervalle interquartile (IQR) ⇒ IQR = Q3 - Q1 = 24 - 8 = 16

Étape 4: Détection des valeurs aberrantes

Borne inférieure :

⇒ $Q1 - 1.5 \times IQR = 8 - (1.5 \times 16) = 8 - 24 = -16$

⇒ Toute valeur **inférieure à -16** est une valeur aberrante. (Aucune ici)

Borne supérieure :

⇒ $Q3 + 1.5 \times IQR = 24 + (1.5 \times 16) = 24 + 24 = 48$

⇒ Toute valeur **supérieure à 48** est une valeur aberrante.

Ici on a 100 > 48 ⇒ Valeur aberrante détectée.

Data Transformation

Définition:

La transformation des données (Data transformation) est un processus essentiel qui permet de préparer des données brutes pour l'analyse. Cela inclut la modification de la structure et du format des données afin de les rendre exploitable.

Différentes techniques de transformation des données peuvent être appliquées aux variables quantitatives et qualitatives :

- ① Pour les variables quantitatives:

Normalisation

Standardisation

- ② Pour les variables qualitatives:

One-Hot Encoding

Label Encoding

Normalisation:

Ajuste les valeurs pour qu'elles se situent sur une échelle commune entre 0 et 1.
 Cette méthode est souvent utilisée dans les algorithmes de Machine Learning qui reposent sur des distances.

Formule:

$$\text{Valeur normalisée} = \frac{X - x_{\min}}{x_{\max} - x_{\min}}$$

Exemple:

Âge	Valeur Normalisée	
15	0	$\min = 15$
22	0.156	$\max = 60$
35	0.444	
40	0.556	
60	1	



Valeur normalisée de l'âge 22 : $\frac{22-15}{60-15} = 0,156$

Standardisation:

Transforme les données pour qu'elles aient une moyenne de 0 et un écart-type de 1, ce qui permet de centrer et d'homogénéiser les données.

Formule: Valeur standardisée = $\frac{X-\mu}{\sigma}$, avec μ la moyenne et σ l'écart-type.

Salaire	Valeur Standardisée (Z)
30000	-1.41
45000	-0.7
60000	0
75000	0.7
90000	1.41



$$\mu = 60000, \quad \sigma = 21213.2$$

Valeur standardisée pour le salaire 30000 :

$$\frac{30000 - 60000}{21213.2} = -1.41$$

Rappel : L'écart-type σ d'une population est calculé comme suit :

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

avec N : Nombre total d'observations dans la population, x_i : valeurs individuelles et μ : moyenne de la population.

Encodage: "One-Hot-Encoding"

Transforme chaque catégorie d'une variable en une nouvelle colonne binaire. Chaque colonne représente une catégorie, avec des valeurs de 1 (présence de la catégorie) ou 0 (absence de la catégorie).

Idéal pour les variables nominales.

Exemple:

Couleur
Rouge
Vert
Bleu
Rouge
Bleu

One-Hot Encoding



	Couleur_Rouge	Couleur_Vert	Couleur_Bleu
Rouge	1	0	0
Vert	0	1	0
Bleu	0	0	1
Rouge	1	0	0
Bleu	0	0	1

Encodage: 'Label Encoding'

Consiste à convertir chaque catégorie d'une variable catégorielle en un nombre entier unique.

Idéal pour les variables ordinale

- Exemple:

Catégorie	Label Encoding
Insatisfait	0
Satisfait	1
Très Satisfait	2

Insatisfait (0) : Indique le niveau le plus bas de satisfaction.

Satisfait (1) : Indique un niveau de satisfaction intermédiaire.

Très Satisfait (2) : Indique le niveau le plus élevé de satisfaction.

Remarque: Pour les variables nominales, le label encoding n'est généralement pas recommandé, car il peut introduire une interprétation erronée des données. Les variables nominales sont des catégories sans ordre naturel.